



UTN Santa Fe – Ing. en Sistemas

Fecha de entrega: 21 Mayo de 2026

Informe TP N.1

Ciencia de Datos

Autores:

Marcos Joaquín Pividori

Luciano Scarpin

Marcos Joaquín Poët

Lucas De Lia

INDICE

Parte 1 - Análisis Exploratorio de Datos	2
1.1 Vista general del Dataset	2
1.2 Variables Categóricas: Proporciones	2
1.3 Medidas Estadísticas de Variables Numéricas.....	2
1.4 Distribuciones de Variables Numéricas	2
1.5 Relaciones entre Variables	2
1.6 Análisis por Tipo de Producto y Estado	2
1.7 Detección de Outliers	2
1.8 Análisis del tool_wear y Falla Acumulada	2
1.9 Resumen de Hallazgos	2
Parte 2 - Preprocesamiento, Modelado y Comparación de Resultados.....	2
Parte 2.1 - Preprocesamiento de datos	2
2.1.1 Análisis de las variables y Tratamiento de Valores Erróneos, Faltantes y Atípicos.....	2
2.1.2 Correlación entre variables.....	2
2.1.3 Procesamiento de variables categóricas	2
2.1.4 División del conjunto de datos	2
2.1.5 Normalización del conjunto de datos:.....	2
Parte 2.2 - Entrenamiento y evaluación de Modelos	2
2.2.1 Regresión Logística: Configuración y Ajuste de Hiperparámetros	2
2.2.2 Árbol de Decisión: Configuración y Poda previa	2
2.2.3 Justificación de las Métricas de Evaluación Seleccionadas y Análisis Comparativo de Resultados.....	2
Parte 2.3 - Entrenamiento de Modelo Ensamblado	2
2.3.1 Justificación y optimización:	2
2.3.2 Resultados y análisis de desempeño	2
2.4 - Comparación de Resultados	2
2.4.1 Análisis de las Matrices de Confusión	2

Parte 1 - Análisis Exploratorio de Datos

1.1 Vista general del Dataset

A partir del análisis del resumen estadístico general, se identifican los aspectos cruciales del mismo:

	air_temp [k]	process_time [k]	speed [Rpm]	torque [Nm]	tool_wear [min]
Conteo	14481	14521	14521	14521	14521
Media	300.48	310.16	1513.39	44.95	124.92
Desviación Estándar	1.95	1.33	313.60	14.23	70.10
Valor Mínimo	295.30	305.70	- 1.0	3.80	0
Cuartil 25	298.90	309.20	1354.0	36.0	64.0
Cuartil 50	300.60	310.32	1423.0	46.70	127.0
Cuartil 75	302.20	311.09	1561.0	55.0	193.0
Valor Máximo	304.50	313.80	2886.0	76.60	253.0

Tabla 1 - Resumen Descriptivo de las variables

A partir del análisis del resumen estadístico general, se identifican tres aspectos cruciales que impactan en la calidad del *dataset*:

1. **Valores Faltantes:** Se registra la ausencia de 40 valores en la variable `air_temp`, lo que requiere una estrategia de imputación o manejo de datos nulos en un futuro procesamiento.
2. **Inconsistencia Física:** La variable `speed` presenta una anomalía física (error de lectura, pérdida de señal o un sensor desconectado), dado que el valor mínimo registrado es de -1.0 RPM, lo cual es inviable en el contexto de la medición y debe ser corregido o eliminado.

3. **Dispersión, Estabilidad y Comportamiento de Planta:** Al analizar los cuartiles se observa una marcada diferencia en la dinámica operativa de las variables.

Por un lado, tool_wear exhibe saltos prácticamente equitativos entre sus cuartiles, lo que revela una **distribución uniforme**. Esto indica una estabilidad en la gestión de mantenimiento, conviviendo en el dataset la misma proporción de herramientas nuevas, a medio uso y desgastadas.

En contraste, las variables de temperatura muestran rangos intercuartílicos muy estrechos y concentrados revelando más una **distribución normal**, reflejando un ambiente térmico altamente controlado. Sin embargo, la dispersión proporcional en el torque (con máximos muy alejados de su Q3) evidencia que el esfuerzo mecánico varía de forma mucho más agresiva que el clima del proceso, posicionando a los picos de torque como los principales indicadores a evaluar ante posibles anomalías o fallas.

1.2 Variables Categóricas: Proporciones




Gráfico 1 - Proporción de Tipos de Fallas y Tipos de Productos Fabricados




Gráfico 2 - Proporción de fallas con respecto a la totalidad de productos de cada tipo

Como se muestra en el Gráfico 1, el producto tipo L representa el 71% del total de productos fabricados. A su vez, el Gráfico 2 indica que este mismo tipo de producto presenta la mayor tasa de fallas internas. Esta combinación de factores implica que la mayor proporción de las fallas de la industria se origina en el producto tipo L. Por lo tanto,

las siguientes etapas del análisis se centrarán en realizar un estudio exhaustivo y detallado de este tipo específico.

1.3 Medidas Estadísticas de Variables Numéricas

	Media	Mediana	Moda
air_temp	300.48	300.60	300.7
process_temp	310.16	310.32	310.6
speed	1513.39	1423.0	1377.0
torque	44.96	46.70	35.8
tool_wear	124.92	127.0	208.0

Tabla 2 - Medidas de Tendencia Central

	Desviación Estándar	Varianza	Rango	IQR	Coefficiente de Variación (%)
air_temp	1.95	3.81	9.20	3.30	0.65
process_temp	1.33	1.77	8.10	1.89	0.43
speed	313.60	98347.57	2887.0	207.0	20.72
torque	14.23	202.40	72.8	19.01	31.65
tool_wear	70.11	4914.85	253.0	129.0	56.12

Tabla 3 - Medidas de Dispersión

	Mín	Q1	Mediana (Q2)	Q3	Máx	Asimetría	Curtosis
--	-----	----	--------------	----	-----	-----------	----------

air_temp	295.3	298.90	300.60	302.20	304.5	-0.220	-0.94
process_temp	305.7	309.20	310.32	311.09	313.8	-0.220	-0.24
speed	-1.0	1354.0	1423.0	1561.0	2886.0	2.08	7.99
torque	3.8	36.0	46.70	55.0	76.6	-0.52	-0.02
tool_wear	0	64.0	127.0	193.0	253.0	-0.16	-1.29

Tabla 4 - Forma de las Distribuciones

Análisis del Resumen Estadístico Numérico:

1. **Alerta de Telemetría en Velocidad:** Se observa una discrepancia entre la Media y la Mediana de la velocidad. Este distanciamiento matemático confirma el impacto del valor erróneo -1.0, el cual genera una asimetría artificial y altera las métricas de tendencia central de la variable.
2. **Contraste de Volatilidad (CV):** Las temperaturas (air_temp y process_temp) exhiben una dispersión mínima respecto a sus medias, lo que demuestra una estabilidad térmica absoluta en el entorno de manufactura. Por el contrario, el torque y el tool_wear muestran coeficientes de variación elevados, consolidándose como las variables con mayor dinamismo y cambios abruptos durante la operación de los equipos.

1.4 Distribuciones de Variables Numéricas




Gráfico 3 - Distribución de Variables Numéricas

1. **Temperatura del aire y del proceso:** Aunque la temperatura del aire muestra un perfil más achatado e irregular en la cima, ambas campanas son casi simétricas. Esto se puede ver ya que la línea roja (Media) y la línea naranja (Mediana) están completamente acopladas, una encima de la otra. Esto confirma que el ambiente térmico de la planta está controlado de forma ideal. No hay días con picos de calor o frío extremo que distorsionen los datos, siguen una distribución Normal.
2. **Velocidad:** Se puede apreciar que la campana principal se concentra de forma muy prolija entre las 1200 y 1800 RPM. Sin embargo, ese valor de -1 a la izquierda del gráfico supondría que la media está más desplazada hacia la izquierda que lo que debería, pero como la densidad de la cola de la derecha es mayor que la de la izquierda la Media termina siendo arrastrada hacia la derecha por el uso intensivo a altas revoluciones de las máquinas.
3. **Torque:** El torque tiene una distribución simétrica muy bien formada, donde la media y la mediana vuelven a estar bastante pegadas en el centro, pero lo interesante es que mientras que las temperaturas están comprimidas en rangos chicos, el torque se desparrama desde valores menores a 20 Nm hasta casi 80 Nm. Esto nos dice visualmente que la fuerza que hacen los motores es sumamente dinámica y varía según la pieza que estén maquinando.
4. **Desgaste de Herramienta:** A comparación de los demás gráficos, este sigue una distribución uniforme (lo podíamos ver entre la diferencia del valor mínimo, los cuartiles y el máximo en el punto anterior). También se puede observar que los valores “atípicos” están más a la derecha (asociados al uso más longevo de la herramienta).




Gráfico 4 - Gráfico de Caja de Variables Numéricas

Este tipo de gráfico es útil ya que “esconde” la distribución dentro de la caja (ya que no nos interesa en este gráfico) y expone esos valores atípicos o outliers con los que trabajaremos más adelante.




Gráfico 5 - Gráfico de Caja Comparativo

En este gráfico la caja naranja muestra el comportamiento que tenía la máquina cuando se rompió y la azul muestra el comportamiento normal. Esto nos permite analizar claramente los “culpables” de que se produzcan distintas fallas en la industria.

1. En el gráfico la caja naranja del torque está más arriba que la azul y en la velocidad pasa al revés, esto nos dice que las máquinas se rompen cuando hacen demasiada fuerza (torque elevado) y el motor de la máquina justamente se frena (velocidad baja).
2. Con respecto al desgaste de la herramienta (tool_wear) también podemos observar que mientras más nueva es la herramienta menos fallas ocurrirán.
3. Con respecto a las temperaturas, se puede analizar que las fallas se producen en un ambiente térmicamente más elevado pero no demasiado.

Distribución de densidad (KDE) por estado del equipo




Gráfico 6 - Gráfico de Distribución de Densidad

1.5 Relaciones entre Variables

El objetivo de esta sección es analizar de forma más específica las distintas relaciones entre las variables para luego asociarlas a las fallas.




Gráfico 7 - Matriz de Correlación

Con esta matriz ya podemos confirmar lo que se venía debatiendo en gráficos anteriores:

1. Las dos temperaturas están fuertemente correlacionadas, quiere decir que si una sube la otra también lo hará casi de forma lineal. En futuros entrenamientos de modelos podríamos prescindir de una de ellas ya que no tendría sentido alimentar con la “misma” información dos veces.
2. La otra gran correlación y que era de esperar es entre el torque y la velocidad. Estas están relacionadas también casi linealmente pero de forma negativa, es decir, si una aumenta la otra disminuye o viceversa y tiene sentido físico ya que si un motor gira a una gran velocidad tiene muy poca fuerza.
3. Una última observación que se aprecia es que el desgaste de la herramienta no tiene ninguna relación con otra variable. Como se pudo ver en gráficos anteriores, si la herramienta tenía ya mucho tiempo de uso las fallas empezaban a aparecer, con la matriz ahora se puede confirmar que esto no depende de la velocidad o el torque.




Gráfico 8 - Gráfico de Dispersión de Distintas Relaciones

De este gráfico se resalta la correlación positiva de las temperaturas y como las fallas no están concentradas en un solo lugar sino en toda la nube de puntos, esto corrobora que la temperatura por sí sola no es un buen discriminador de fallas.

Otra observación clave es la correlación negativa entre la velocidad y el torque, donde los puntos de fallas no están dispersos aleatoriamente sino que forman una especie de frontera

alrededor de la nube de puntos azules asociados al comportamiento normal. Por lo tanto, las fallas se agrupan dramáticamente en los extremos:

- Alta velocidad y bajo torque -> podría ser un fallo de sobre-revoluciones.
- Baja velocidad y alto torque -> podría ser una sobrecarga mecánica

1.6 Análisis por Tipo de Producto y Estado




Gráfico 9 - Tabla de Media Estandarizada por Tipo de Producto y Estado

La estandarización nos permite comparar la magnitud del impacto de cada feature eliminando el sesgo de sus unidades de medida originales.

El gráfico revela la jerarquía de los factores de falla: el tool_wear se posiciona como el predictor individual más fuerte, presentando la desviación positiva más pronunciada respecto a la media global durante los eventos de rotura.

En segundo lugar, se confirma la dinámica de sobrecarga electromecánica, evidenciada por un fuerte incremento del torque acompañado de una caída proporcional en la velocidad. Finalmente, las desviaciones estandarizadas de las variables térmicas son despreciables frente a las mecánicas, relegando su importancia predictiva de forma aislada.




Gráfico 10 - Distribución por Tipo de Producto y Estado

Este gráfico permite observar simultáneamente las medidas de tendencia central y la densidad de los datos, dividido por cada tipo de producto.

Nos permite destacar:

- Las distribuciones de las variables térmicas y mecánicas exhiben geometrías, amplitudes y medianas prácticamente idénticas a través de las tres líneas de producción. Esto demuestra que el programa de control de la maquinaria no altera su configuración base, es decir, el régimen de esfuerzo y las revoluciones nominales se mantienen constantes sin importar el tipo de producto.
- La distribución de velocidad grafica claramente la asimetría positiva de la variable, mostrando una mayor concentración de densidad desplazada hacia el límite superior de revoluciones y una "cola" más fina que desciende hacia los valores mínimos operativos.
- El gráfico correspondiente a tool_wear se distingue por una forma rectangular ensanchada a lo largo de todo el eje vertical, carente de un abultamiento central. Esto ratifica la idea de que la herramienta recorre su ciclo de vida completo sin reemplazos preventivos.

1.7 Detección de Outliers

Los outliers son valores atípicos o basura en muchos datasets y generalmente se descartan, pero en este contexto nos aportan la información necesaria de “cuando” o “como” se va a producir una falla, para luego alimentar ese conocimiento a los distintos modelos entrenados.

En este trabajo se ocupó el rango intercuartílico para detectar estos valores: $IQR = Q3 - Q1$

Cualquier dato que caiga fuera de ese rango se considerará un outlier.

variable	número de outliers	porcentaje del total de la variable	límite inferior	límite superior
air_temp	0	0%	293.95	307.15
process_temp	67	0.46%	306.37	313.92
speed	1186	8.17%	1043.50	1871.50
torque	107	0.74%	7.48	83.52
tool_wear	0	0%	-129.50	386.50

Tabla 5 - Outliers por Criterio IQR

La tabla muestra:

- La temperatura del aire está controlada evidenciando un entorno industrial climatizado y sin picos térmicos ambientales.
- Los límites del desgaste de la herramienta contiene todo el ciclo de vida de la misma, como no presenta desvíos atípicos, el desgaste progresa como una variable temporal continua y predecible.
- La temperatura del proceso registra una cantidad moderada de valores atípicos fuera del rango, representando eventos puntuales donde la disipación térmica local de la herramienta rozó sus límites.
- La velocidad tiene la mayor cantidad de valores atípicos, esta alta concentración describe la naturaleza dinámica del motor, el cual altera frecuentemente sus revoluciones para compensar las demandas de carga en el proceso de mecanizado.

- El torque presenta un comportamiento más estricto, al ser una variable que trabaja habitualmente bajo un régimen controlado, los 107 picos que escapan a este límite representan esfuerzos mecánicos severos sufridos por el equipo.

1.8 Análisis del tool_wear y Falla Acumulada




Gráfico 11 - Histograma de fallas según el desgaste

Se puede ver en el gráfico que el mayor porcentaje de fallas ocurre cuando la herramienta llega al punto final de su vida útil, y las fallas producidas al principio ya son más ajenas al desgaste.

1.9 Resumen de Hallazgos

- Dataset: 14521 registros y 9 columnas.
- Calidad de Datos:
 - air_temp: 40 valores nulos.
 - Velocidad mínima = - 1 RPM, valor físicamente imposible (erróneo).
 - Sin filas duplicadas.
- Balance de Clases:
 - Normal: 48.5% / Falla: 51.5%
- Tipo de Producto:
 - Predomina el tipo L (71.4%), seguido por M (18.5%) y H (10.1%).
 - Tasa de Falla por tipo:
 - H → 49.9%
 - L → 59.8%
 - M → 20.4%

- Relaciones:
 - Velocidad y torque fuertemente correlacionadas (casi linealmente negativa).
 - Las temperaturas están fuertemente correlacionadas (casi linealmente positiva).
 - El desgaste no está correlacionado con ninguna variable.

Parte 2 - Preprocesamiento, Modelado y Comparación de Resultados

Parte 2.1 - Preprocesamiento de datos

El objetivo fundamental de esta etapa consiste en transformar el conjunto de datos en crudo en una estructura óptima y compatible con los algoritmos de aprendizaje automático. El preprocesamiento es una fase crítica, ya que la calidad de las predicciones de los modelos está directamente condicionada por la consistencia, el escalado y la representatividad de los datos de entrada. En este inciso, se abordan las problemáticas identificadas durante el Análisis Exploratorio de Datos, tales como la presencia de registros erróneos, registros faltantes y la asimetría en las distribuciones.

2.1.1 Análisis de las variables y Tratamiento de Valores Erróneos, Faltantes y Atípicos

A partir de las conclusiones obtenidas en el Análisis exploratorio de Datos, se procedió a la depuración del dataset enfocado en las variables críticas del sistema:

- **Imputación de Valores Faltantes:** Se detectó la existencia de 40 registros nulos (NaN) en la variable correspondiente a la temperatura del aire. Dado que el volumen de datos faltantes representa una fracción marginal del dataset total (aproximadamente un 0.27% de las 14.500 observaciones), descartar las filas completas significaría una pérdida innecesaria de información en otros atributos operativos. En su lugar, se optó por una estrategia de imputación robusta utilizando la mediana del conjunto de entrenamiento. Se seleccionó la mediana en detrimento de la media aritmética debido a su propiedad no paramétrica, la cual garantiza inmunidad ante eventuales sesgos o distorsiones causadas por lecturas extremas en los extremos de la distribución.
- **Corrección de Valores Erróneos por Fallas de Captura:** El análisis exploratorio reveló la presencia de registros con un valor de -1 (RPM) en la velocidad de rotación de los equipos. Físicamente, una velocidad angular negativa no posee un sentido operativo válido por lo que mantener este valor de -1 alteraría la distribución afectando directamente el cálculo de gradientes y coeficientes en modelos lineales. Para resolverlo, se reemplazaron matemáticamente estas banderas de error sustituyéndolas por la mediana operativa de la velocidad, reintegrando los registros a la distribución normal del proceso sin alterar el comportamiento global de la variable.
- **Valores Atípicos (Outliers):** Se detectaron valores atípicos en las variables numéricas, por lo cual para mitigar el impacto de estos valores extremos en modelos sensibles, se aplicaron técnicas de filtrado basadas en rangos intercuartílicos (IQR), asegurando que el modelo generalice sobre comportamiento de maquinaria real y no sobre fallas de lectura de los sensores.

2.1.2 Correlación entre variables

Antes de avanzar hacia el entrenamiento de los modelos, se realizó un análisis de las relaciones lineales existentes entre las variables numéricas del sistema mediante una matriz de correlación. El objetivo principal de este paso fue identificar la presencia de

multicolinealidad (variables que aportan información redundante), un fenómeno que afecta negativamente la estabilidad y la interpretabilidad de ciertos modelos.

A partir de este análisis, se destacaron dos comportamientos críticos:

- Torque vs. Velocidad de Rotación: Se detectó una correlación negativa muy marcada.
- Temperatura del Aire vs. Temperatura del Proceso: Se observó una correlación positiva extremadamente fuerte (cercana a 1). Esto indica que ambas variables evolucionan en paralelo y aportan prácticamente la misma información estadística al modelo.

Por lo cual tomamos la decisión de eliminar del dataset la variable `process_temp` [K], conservando únicamente `air_temp` [K], para así resolver la redundancia detectada entre las temperaturas y evitar problemas de multicolinealidad en los modelos lineales.

2.1.3 Procesamiento de variables categóricas

La variable `product_type` representa el tipo de producto y tiene tres valores diferentes (L, M y H) . Dado que los algoritmos de aprendizaje automático operan exclusivamente con matrices numéricas y no pueden interpretar texto directamente, fue necesario realizar una codificación.

Para evitar introducir un orden jerárquico artificial que confunda a los modelos, se aplicó la técnica de codificación One-Hot Encoding, este proceso transforma la columna categórica original en tres columnas binarias independientes (una para cada tipo de producto), donde se asigna un 1 si el registro pertenece a esa categoría y un 0 en caso contrario. De esta manera, el modelo puede evaluar de forma equitativa si un tipo específico de maquinaria tiene mayor o menor predisposición a sufrir averías.

2.1.4 División del conjunto de datos

Para validar que los modelos que entrenaremos posteriormente se comporten de manera correcta, y puedan extraer relaciones entre los datos, resulta indispensable dividir el conjunto de datos en distintos conjuntos para el entrenamiento, validación y prueba, asegurando así una evaluación rigurosa del rendimiento sobre datos no observados mitigando eficazmente riesgos de sobreajuste.

- Conjunto de entrenamiento: Se tomó el 70 % de los datos y se los destinó exclusivamente al ajuste de los parámetros internos de los modelos.
- Conjunto de validación: Se utilizó un 15 % de los datos restantes, este conjunto es utilizado como un entorno de prueba intermedio. Su propósito es guiar la búsqueda

de los mejores hiperparámetros, permitiendo comparar configuraciones de forma justa.

- Conjunto de pruebas (test): El 15 % restante de los datos, quedó reservado para la evaluación final. Este conjunto simula el comportamiento de los modelos en producción frente a datos de maquinaria completamente nuevos y nunca antes vistos.

2.1.5 Normalización del conjunto de datos:

Las variables físicas de entrada manejan escalas numéricas y órdenes de magnitud completamente dispares; por ejemplo, la temperatura del aire oscila en torno a los 300 Kelvin, mientras que la velocidad de rotación supera las 1400 RPM y el desgaste de la herramienta se mide en decenas de minutos. Algunos algoritmos calculan distancias geométricas y gradientes, por lo que se verían severamente sesgados hacia aquellas variables con magnitudes numéricas más altas.

Para asegurar que todas las características influyen con el mismo peso matemático en el modelo, se aplicó una estandarización. Este proceso transforma las variables numéricas de modo que pasen a tener una media de 0 y una desviación estándar de 1. Es fundamental destacar que el escalador se ajustó exclusivamente con los datos del subconjunto de entrenamiento y posteriormente se empleó para transformar los conjuntos de validación y prueba. Esta estricta separación metodológica previene la "fuga de datos" (data leakage), garantizando que la información estadística del testeo no contamine el proceso de aprendizaje algorítmico.

Parte 2.2 - Entrenamiento y evaluación de Modelos

En este apartado se detalla el proceso de construcción, optimización y evaluación de los primeros dos clasificadores supervisados seleccionados para resolver el problema de mantenimiento predictivo. Con el propósito de abordar el problema desde diferentes enfoques matemáticos, se seleccionó un modelo lineal (Regresión Logística) y un modelo no lineal basado en reglas (Árbol de Decisión).

2.2.1 Regresión Logística: Configuración y Ajuste de Hiperparámetros

La Regresión Logística se estableció como el modelo de línea de base (baseline) debido a su simplicidad, rapidez de entrenamiento y facilidad de interpretación en términos de probabilidades de ocurrencia de un evento. Al tratarse de un clasificador lineal, busca trazar un hiperplano geométrico que separe las condiciones de operación normales de los estados de falla.

Para maximizar su rendimiento y evitar problemas de sobreajuste o falta de convergencia, se realizó una búsqueda sistemática sobre el conjunto de validación evaluando los siguientes hiperparámetros:

- Parámetro de Regularización (C): Controla el inverso de la fuerza de la penalización (por defecto de tipo L2 o Ridge). Valores más bajos aplican una regularización más estricta para simplificar los coeficientes, mientras que valores altos permiten un

ajuste más libre a los datos. El proceso de optimización seleccionó un valor de $C = 0.01$, indicando que el modelo requirió una fuerte restricción para mantener la estabilidad frente al ruido de las variables físicas y generalizar correctamente.

- Algoritmo de Optimización (Solver): Se evaluaron las opciones de convergencia analizando el comportamiento de los solucionadores liblinear y lbfgs. La optimización determinó que liblinear fue la alternativa más eficiente para encontrar el límite de decisión óptimo dadas las dimensiones del conjunto estructurado.

2.2.2 Árbol de Decisión: Configuración y Poda previa

Como contrapartida al enfoque lineal, se implementó un Árbol de Decisión (DecisionTreeClassifier) con el objetivo de capturar las interacciones no lineales y complejas que caracterizan a las variables del entorno industrial (como la relación inversa entre el torque y la velocidad).

Dado que un árbol sin restricciones tiende a ramificarse de manera indefinida hasta que todas sus hojas queden puras lo que provoca que el modelo memorice perfectamente el conjunto de entrenamiento pero falle severamente ante datos nuevos se aplicaron criterios de poda previa (pre-pruning) mediante la búsqueda de los siguientes hiperparámetros:

- Profundidad Máxima (max_depth): Determina el límite de preguntas consecutivas que el algoritmo puede realizar sobre los atributos. La exploración seleccionó una profundidad de 15 niveles. Este límite detiene el crecimiento del árbol de forma anticipada, impidiendo la creación de reglas excesivamente específicas que representen ruido estadístico y garantizando una mejor capacidad de generalización.
- Criterio de División (criterion): Evalúa la métrica matemática utilizada para medir la calidad y pureza de las particiones en cada nodo intermedio. Se contrastaron la ganancia de información (entropía) y el índice de Gini, resultando este último seleccionado por la optimización como la opción más idónea. El índice de Gini minimiza la probabilidad de clasificar incorrectamente una observación aleatoria dentro del nodo, estructurando de manera muy eficiente las fronteras de decisión del dataset.

2.2.3 Justificación de las Métricas de Evaluación Seleccionadas y Análisis

Comparativo de Resultados

Para medir la efectividad real de ambos algoritmos en el conjunto de prueba, se descartó el uso exclusivo de la exactitud global (Accuracy). En problemas de mantenimiento predictivo, evaluar un modelo únicamente por su tasa de aciertos general es insuficiente y metodológicamente peligroso, ya que un error de omisión tiene un impacto económico crítico.

Por lo tanto, la evaluación se fundamentó en las siguientes métricas clave:

- Recall (Sensibilidad): Mide la capacidad del modelo para detectar correctamente la totalidad de las fallas reales presentes en la maquinaria.
- F1-Score: Proporciona una medida de equilibrio armónico entre la precisión y el recall. Nos permite asegurar que el incremento en la detección de fallas no se consiga a costa de disparar un número desmedido de Falsos Positivos.

Tras la fase de entrenamiento y optimización, los modelos fueron evaluados sobre el conjunto de prueba, obteniendo desempeños diferenciados que se pueden ver en la siguientes tablas:

Métrica	Regresión Logística	Árbol de decisión
Accuracy	0.7779	0.9468
Recall	0.8077	0.9573
F1-Score	0.7894	0.9488

Tabla 6 - Resultados obtenidos del entrenamiento y optimización de los modelos.

	Precisión	Recall	F1-Score	Soporte
0	0.78	0.75	0.77	1056
1	0.77	0.81	0.79	1123
Accuracy	-	-	0.78	2179
Macro Avg	0.78	0.78	0.78	2179
Weighted Avg	0.78	0.78	0.78	2179

*Tabla 7 - Reporte de clasificación del modelo de **Regresión Logística**.*

	Precisión	Recall	F1-Score	Soporte
0	0.95	0.94	0.94	1056
1	0.94	0.96	0.95	1123
Accuracy	-	-	0.95	2179
Macro Avg	0.95	0.95	0.95	2179
Weighted Avg	0.95	0.95	0.95	2179

*Tabla 8 - Reporte de clasificación del modelo de **Árbol de decisión**.*

Viendo los datos de la tabla podemos llegar a las siguientes conclusiones:

- **Superioridad del Modelo No Lineal:** Se evidencia una diferencia significativa a favor del Árbol de Decisión. Mientras que la Regresión Logística alcanza un F1-Score del 78.9 %, el Árbol de Decisión escala hasta un 94.9 %. Este salto en el rendimiento confirma que la relación entre las variables físicas del proceso (temperatura, torque, desgaste) y la probabilidad de falla no es lineal. El modelo lineal de la Regresión Logística, al intentar trazar una frontera de decisión plana, subestima la complejidad de los datos, mientras que el Árbol de Decisión logra segmentar con éxito el espacio de características mediante reglas locales.
- **Estabilidad y precisión:** El informe de clasificación muestra una gran consistencia en el Árbol de Decisión, con precisiones y recalls equilibrados para ambas clases (0 y 1), situándose ambos por encima del 94%. Por su parte, la Regresión Logística muestra dificultades para generalizar, con una precisión más baja que genera un mayor número de falsas alarmas (falsos positivos).

Parte 2.3 - Entrenamiento de Modelo Ensamblado

Para elevar la precisión del sistema de mantenimiento predictivo, se implementó un modelo de ensamblado basado en Bosques Aleatorios (Random Forest). Esta técnica mejora la capacidad predictiva al combinar múltiples árboles de decisión individuales que operan en paralelo.

2.3.1 Justificación y optimización:

La arquitectura de los bosques aleatorios aporta dos ventajas clave para este conjunto de datos:

- **Reducción del sobre ajuste:** Al utilizar una técnica llamada bagging (muestreo aleatorio con reemplazo) junto con un subespacio aleatorio de características, el modelo evita que los errores individuales de cada árbol sesguen la predicción final, logrando una mayor robustez frente al ruido de los sensores.

- Eficiencia computacional: Dado que cada árbol se entrena de forma independiente, se aprovechó la arquitectura multinúcleo del procesador, reduciendo significativamente el tiempo de entrenamiento sin sacrificar rendimiento.

Tras la búsqueda de hiperparámetros sobre el conjunto de validación, se seleccionó la configuración óptima:

- Número de estimadores (n_estimators): Se utilizaron 200 árboles de decisión. Un mayor número de estimadores incrementa la estabilidad del modelo al promediar las predicciones, lo que resulta en un conjunto más robusto y menos propenso al error.
- Máximas características (max_features): Se utilizó la raíz cuadrada del número total de características para cada división. Esta configuración garantiza que los árboles mantengan una alta diversidad entre sí.
- Profundidad máxima (max_depth): Se permitió el crecimiento ilimitado de los árboles, ya que el efecto de promediar cientos de ellos compensa naturalmente el riesgo de sobreajuste que sufriría un árbol individual.

2.3.2 Resultados y análisis de desempeño

Los resultados obtenidos en el conjunto de prueba confirman que el modelo ensamblado es la opción más sólida y eficaz:

Métrica	Valor
Accuracy	0.9651
Recall	0.9768
F1-Score	0.9665

Tabla 9 - Resultados obtenidos del entrenamiento y optimización del modelo *Bosque Aleatorio*.

	Precisión	Recall	F1-Score	Soporte
0	0.97	0.95	0.96	1056
1	0.96	0.98	0.97	1123
Accuracy	-	-	0.97	2179
Macro Avg	0.97	0.96	0.97	2179
Weighted Avg	0.97	0.97	0.97	2179

Tabla 10 - Reporte de clasificación del modelo de *Bosque Aleatorio*.

Luego de ver estos resultados llegamos a la conclusión de que el modelo Bosque Aleatorio alcanzó una sensibilidad (Recall) del 97.68%, superando significativamente al Árbol de Decisión simple y a la Regresión Logística. Este valor confirma que el modelo es altamente fiable para la detección temprana de averías, reduciendo el riesgo de fallas no identificadas

(falsos negativos) a un nivel mínimo. La consistencia en todas las métricas valida a este modelo como el más apto para su despliegue en un entorno real.


2.4 - Comparación de Resultados

Una vez entrenados, optimizados y evaluados los tres clasificadores supervisados, el modelo lineal (Regresión Logística), el modelo no lineal basado en reglas (Árbol de Decisión) y el modelo de ensamblado (Bosque Aleatorio), en este apartado se consolidan sus desempeños sobre el conjunto de prueba con el objetivo de seleccionar la alternativa más adecuada para el problema de mantenimiento predictivo. La comparación se sustenta en las mismas métricas empleadas a lo largo del trabajo (Accuracy, Recall y F1-Score), priorizando aquellas que reflejan la capacidad real del modelo para anticipar las fallas de la maquinaria.

Tabla 9 - Comparación de métricas de los tres modelos sobre el conjunto de prueba.

Modelo	Accuracy	Recall	F1-Score
Regresión Logística	0.7779	0.8077	0.7894
Árbol de Decisión	0.9468	0.9573	0.9488
Bosque Aleatorio	0.9651	0.9768	0.9665

Gráfico 12 - Comparación gráfica del rendimiento de los modelos sobre el conjunto de prueba.



Los resultados evidencian una jerarquía de desempeño clara y consistente entre los tres enfoques:

- Brecha entre el modelo lineal y los modelos basados en árboles: La Regresión Logística queda muy por detrás de las otras dos alternativas, con un F1-Score del 78.9 % frente al 94.9 % del Árbol de Decisión y al 96.7 % del Bosque Aleatorio. Esta diferencia confirma lo anticipado en el Análisis Exploratorio de Datos: la relación entre


las variables físicas del proceso y la ocurrencia de fallas no es linealmente separable, por lo que un único hiperplano resulta insuficiente para modelar el fenómeno.

- Mejora aportada por el ensamblado: El Bosque Aleatorio supera al Árbol de Decisión individual en las tres métricas (Accuracy 96.5 % frente a 94.7 %, Recall 97.7 % frente a 95.7 % y F1-Score 96.7 % frente a 94.9 %). Al promediar las predicciones de múltiples árboles entrenados sobre subconjuntos aleatorios de registros y atributos, el ensamblado reduce la varianza del modelo y mitiga el sobreajuste, logrando una frontera de decisión más robusta y estable.
- El Recall como métrica decisiva: En un contexto de mantenimiento predictivo, el Recall es la métrica crítica, ya que mide la proporción de fallas reales efectivamente detectadas. El Bosque Aleatorio alcanza el Recall más alto (97.7 %), lo que significa que es el modelo que menos fallas deja pasar inadvertidas, minimizando el riesgo de paradas no planificadas y los costos asociados a las averías.

2.4.1 Análisis de las Matrices de Confusión

Para complementar la lectura de las métricas agregadas, se analizan las matrices de confusión de cada modelo sobre el conjunto de prueba. Estas permiten observar de forma desglosada los aciertos y, fundamentalmente, los dos tipos de error: los Falsos Negativos (fallas reales que el modelo clasificó como operación normal) y los Falsos Positivos (equipos en estado normal señalados erróneamente como falla).

Gráfico 13 - Matrices de confusión de los tres modelos sobre el conjunto de prueba.



El conjunto de prueba está compuesto por 2179 registros (1056 casos normales y 1123 fallas). El comportamiento de cada modelo frente a los errores de clasificación es el siguiente:

- Regresión Logística: Presenta el desempeño más débil, con 216 fallas no detectadas (Falsos Negativos) y 268 falsas alarmas (Falsos Positivos). Una omisión de esta magnitud resulta inadmisibles en un sistema de mantenimiento predictivo, ya que casi una de cada cinco fallas reales pasaría desapercibida.
- Árbol de Decisión: Reduce drásticamente ambos tipos de error, dejando 48 fallas sin detectar y 68 falsas alarmas. Su comportamiento es equilibrado y confirma su buena capacidad para capturar las interacciones no lineales del proceso.
- Bosque Aleatorio: Obtiene el mejor resultado global, con apenas 26 Falsos Negativos y 50 Falsos Positivos. Es el modelo que menos fallas reales deja escapar, lo que se traduce directamente en su Recall superior.

A partir del análisis comparativo, se concluye que el Bosque Aleatorio constituye la mejor solución para el problema planteado. No solo lidera todas las métricas de evaluación, sino que minimiza los Falsos Negativos, el error de mayor impacto económico en el dominio del mantenimiento predictivo, ofreciendo además una mayor estabilidad gracias a su naturaleza de ensamblado. Por lo tanto, se lo selecciona como el modelo final recomendado para anticipar las fallas de la maquinaria industrial.